

# NeolA Security Portal

Proposta de MVP para plataforma de IA aplicada a suporte técnico, análise de logs e governança em cibersegurança

**Preparado para discussão interna de projeto de IA na Neotel**

Data: 24/05/2026

## Resumo da proposta

Criar uma interface única com duas alas: uma ala técnica, com chatbot baseado em conhecimento interno e geração assistida de chamados; e uma ala de governança, com análise de logs de ferramentas como STA e DLP para geração de relatórios executivos e técnicos. O MVP pode aproveitar a infraestrutura ESXi/DL360 ou DL380 já disponível, com opção de IA local via Ollama ou IA em nuvem via Amazon Bedrock, OpenAI API ou Azure OpenAI.

## Sumário Executivo

Este documento consolida a proposta discutida para criação de uma plataforma interna de IA voltada à realidade da Neotel, considerando cibersegurança, operação técnica, suporte, governança e integração com ferramentas já disponíveis, como Octadesk e logs do STA.

A proposta é viável tecnicamente e pode ser construída em fases. O MVP recomendado utiliza uma VM Linux no ESXi existente, com processamento controlado, integração inicial com logs do STA, geração de relatório e criação assistida de chamados no Octadesk. A IA pode operar localmente via Ollama ou em nuvem via Amazon Bedrock/OpenAI/Azure OpenAI, conforme o nível de privacidade, custo e desempenho desejado.

| Critério                        | Avaliação                                                                                                   |
|---------------------------------|-------------------------------------------------------------------------------------------------------------|
| Viabilidade técnica             | Alta, desde que o escopo inicial seja reduzido e progressivo.                                               |
| Complexidade de desenvolvimento | Média. A maior complexidade está em organizar a base de conhecimento, criar parsers e desenhar bons fluxos. |
| Complexidade de infraestrutura  | Baixa a média para MVP; média/alta apenas se exigir appliance dedicado com GPU.                             |
| Custo inicial                   | Baixo se aproveitar ESXi existente; variável se usar nuvem ou appliance dedicado.                           |
| Principal risco                 | Impacto em host ESXi compartilhado, governança de dados sensíveis e qualidade dos relatórios.               |
| Recomendação                    | Começar com MVP local controlado + opção cloud para comparação de qualidade e custo.                        |

## 1. Conceito do Projeto

O NeolA Security Portal seria uma plataforma única de IA com dois módulos principais: uma ala técnica e uma ala de governança. O objetivo é apoiar tanto o time operacional quanto a geração de valor executivo para clientes e gestores.

| Módulo         | Objetivo                                                                                                   | Principais entregas                                                                                                                   |
|----------------|------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------|
| Ala Técnica    | Apoiar analistas, consultores e suporte técnico na resolução de dúvidas sobre ferramentas e procedimentos. | Chatbot técnico, busca em documentação, geração de passos de troubleshooting, sugestão de evidências e geração assistida de chamados. |
| Ala Governança | Transformar logs e eventos técnicos em relatórios executivos, técnicos e recomendações de segurança.       | Relatórios para STA, DLP/Safetica e futuras ferramentas, classificação de risco, recomendações e criação de insumos para governança.  |

### Mensagem de valor

A proposta não é substituir analistas, SIEM ou ferramentas de segurança existentes. A IA atuaria como uma camada consultiva, capaz de resumir eventos, explicar contexto, recomendar ações e padronizar comunicações técnicas e executivas.

## 2. Ala Técnica - Chatbot e Chamados

A ala técnica funcionaria como um copiloto para analistas e consultores. O usuário faria perguntas sobre ferramentas, erros, integrações, procedimentos e boas práticas. A IA responderia com base em uma base de conhecimento interna e, quando necessário, poderia gerar um rascunho de chamado para o Octadesk.

| Função                   | Descrição                                                                                                              |
|--------------------------|------------------------------------------------------------------------------------------------------------------------|
| Chatbot técnico          | Responde perguntas sobre STA, CTE, DDC, DLP/Safetica, SIEM, IAM, PAM e outros temas definidos.                         |
| RAG/base de conhecimento | Busca documentos internos, playbooks, procedimentos, templates, FAQs e documentação de fabricantes antes de responder. |
| Geração de chamado       | A IA monta título, descrição, impacto, evidências necessárias, produto afetado e severidade sugerida.                  |
| Integração Octadesk      | No MVP, recomenda-se gerar o texto e permitir revisão humana antes da criação via API.                                 |

### Ponto de controle recomendado

Para o MVP, a criação de chamado deve ser assistida, não totalmente automática: a IA gera o conteúdo, o usuário revisa e somente depois clica em "Criar chamado no Octadesk".

## 3. Ala Governança - Relatórios Executivos

A ala de governança seria responsável por analisar logs ou exportações de ferramentas pré-estabelecidas, como STA e DLP/Safetica, e gerar relatórios claros para gestores, clientes e áreas de governança.

| Entrada                       | Processamento                                                                          | Saída                                                                       |
|-------------------------------|----------------------------------------------------------------------------------------|-----------------------------------------------------------------------------|
| Logs do STA via endpoint/API  | Parser, normalização, mascaramento, regras de risco e IA generativa.                   | Relatório executivo, relatório técnico, recomendações e possível chamado.   |
| Exportações de DLP/Safetica   | Agrupamento por usuário, operação, aplicação, política, bloqueios e tendências.        | Resumo de operações, riscos, ações recomendadas e evidência para auditoria. |
| Alertas de SIEM ou CSV manual | Classificação de eventos, volume, severidade, eventos recorrentes e correlação básica. | Resumo para governança, possíveis incidentes e recomendações de resposta.   |

O MVP deve começar com poucas fontes. A recomendação é iniciar por STA, devido à disponibilidade do endpoint de logs, e eventualmente adicionar DLP/Safetica em uma segunda etapa.

## 4. Onde a IA Entra no Processo

A IA não deve receber logs brutos gigantes nem tomar decisões sozinha. O desenho recomendado combina regras determinísticas, processamento em Python, busca em base de conhecimento e geração de linguagem natural.

| Camada              | Papel                                                                            |
|---------------------|----------------------------------------------------------------------------------|
| Parser/normalização | Lê logs brutos, extrai campos importantes e transforma em estrutura padronizada. |


|                 |                                                                                                             |
|-----------------|-------------------------------------------------------------------------------------------------------------|
| Mascaramento    | Remove ou substitui dados sensíveis antes de enviar ao modelo, especialmente em modo nuvem.                 |
| Motor de regras | Identifica padrões como falhas excessivas, MFA negado, acesso fora do horário e usuários com risco elevado. |
| IA generativa   | Transforma os dados estruturados em análise, resumo, recomendação, relatório e texto de chamado.            |
| RAG             | Permite que o chatbot responda com base em documentos internos e playbooks.                                 |

5. Infraestrutura Atual Observada

A evidência enviada mostra um host ESXi com recursos relevantes para um MVP, mas também com grande número de máquinas virtuais e uso de storage considerável. Os números abaixo foram extraídos visualmente do print disponibilizado.

| Item              | Valor observado                                                              |
|-------------------|------------------------------------------------------------------------------|
| Host              | imperial-shuttle.neotel.com.br                                               |
| Fabricante/modelo | HPE ProLiant DL380 Gen10 Plus                                                |
| ESXi              | 8.0                                                                          |
| CPU               | 48 CPUs / capacidade aproximada de 100,6 GHz / uso baixo no momento do print |
| Memória           | 383,45 GB de RAM / cerca de 206,45 GB em uso / 177 GB livres                 |
| Storage           | 3,58 TB de capacidade / cerca de 2,93 TB usado / 668,86 GB livres            |
| Máquinas virtuais | 53 VMs listadas no host                                                      |

Evidência visual da infraestrutura analisada:



Conclusão: é possível hospedar o MVP em uma VM nesse host, mas o Ollama deve ser limitado e usado em processamento assíncrono, preferencialmente fora do horário comercial, para evitar impacto nas demais VMs.

## 6. Opções de Infraestrutura

| Opção                      | Descrição                                                                            | Viabilidade para MVP                                                                      |
|----------------------------|--------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------|
| Local com Ollama no ESXi   | VM Ubuntu no ESXi, Docker, Ollama, modelo 7B/8B quantizado, processamento em lote.   | Alta, desde que limitada a 4-8 vCPU e 16-32 GB RAM.                                       |
| Híbrido com Bedrock        | Portal local faz parser/mascaramento e envia resumo estruturado para Amazon Bedrock. | Alta, com melhor desempenho e qualidade, mas exige política de envio de dados para nuvem. |
| OpenAI/Azure OpenAI        | Similar ao Bedrock, com modelos via API e custo por token.                           | Alta para MVP, principalmente se dados forem mascarados.                                  |
| Appliance dedicado com GPU | Servidor ou workstation com GPU para IA local performática.                          | Boa para produto futuro, mas não necessária no MVP.                                       |

## 7. Arquitetura Recomendada para o MVP

A recomendação é começar com um MVP local controlado, aproveitando o ESXi existente e integrando Octadesk e logs do STA. A arquitetura deve ser modular para permitir trocar o motor de IA entre Ollama e nuvem sem reescrever todo o sistema.

| Componente            | Recomendação para MVP                                    |
|-----------------------|----------------------------------------------------------|
| Sistema operacional   | Ubuntu Server 22.04/24.04                                |
| Virtualização         | VM no ESXi existente                                     |
| Recursos iniciais     | 4 vCPU, 16 GB RAM, 80-100 GB de disco                    |
| Recursos recomendados | 8 vCPU, 32 GB RAM, 150-200 GB de disco                   |
| IA local              | Ollama com modelo 7B/8B quantizado                       |
| Aplicação             | Streamlit para protótipo; FastAPI + frontend em evolução |
| Banco                 | SQLite no protótipo; PostgreSQL em MVP interno           |
| Base vetorial         | ChromaDB ou Qdrant para RAG                              |
| Processamento         | Batch/agendado; relatórios diários ou semanais           |
| Integrações iniciais  | STA Logs API e Octadesk API                              |

## 8. Fluxo Funcional Proposto

Usuário acessa o Portal NeoIA

```
|
+-- Ala Técnica
|   |
|   +-- Chatbot técnico
|   +-- Busca em base de conhecimento
|   +-- Geração de troubleshooting
|   +-- Geração assistida de chamado no Octadesk
|
+-- Ala Governança
|
```

- +-- Coleta ou upload de logs
- +-- Parser e normalização
- +-- Mascaramento de dados
- +-- Motor de regras
- +-- IA local ou nuvem
- +-- Relatório executivo/técnico
- +-- Sugestão de chamado ou ação

## 9. Estimativa de Custos

Os valores abaixo são estimativas de ordem de grandeza para discussão. Custos finais dependem de cotação, modelo escolhido, região cloud, volume de uso, política comercial dos provedores e capacidade disponível no ambiente.

| Cenário                   | Custo de infraestrutura                               | Custo recorrente                                                                 | Observações                                                                                   |
|---------------------------|-------------------------------------------------------|----------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------|
| ESXi existente + Ollama   | Baixo, caso haja capacidade disponível no host atual. | Baixo. Energia/manutenção já existentes; sem custo por token.                    | Mais lento sem GPU, mas aceitável para relatórios assíncronos.                                |
| Bedrock/OpenAI/Azure      | Baixo localmente.                                     | Por token. Pode ser muito baixo se o sistema enviar apenas resumos estruturados. | Melhor qualidade e velocidade, mas exige governança sobre dados enviados.                     |
| Appliance simples com GPU | Estimativa: R\$ 15 mil a R\$ 35 mil.                  | Baixo/médio.                                                                     | Workstation ou servidor simples com GPU de 16-24 GB. Bom para laboratório ou produto inicial. |
| Appliance profissional    | Estimativa: R\$ 50 mil a R\$ 120 mil+.                | Médio.                                                                           | Servidor com suporte, mais RAM, storage e GPU profissional.                                   |
| Appliance enterprise      | Estimativa: R\$ 120 mil a R\$ 300 mil+.               | Médio/alto.                                                                      | Cenário para oferta comercial robusta, suporte e hardware homologado.                         |

### 9.1 Fórmula de custo para IA em nuvem

Em modelos cobrados por tokens, o custo aproximado por relatório pode ser estimado assim:

$$\text{Custo} = (\text{tokens de entrada} / 1.000.000 \times \text{preço de entrada}) + (\text{tokens de saída} / 1.000.000 \times \text{preço de saída})$$

Exemplo de dimensionamento para relatório já pré-processado: 20.000 tokens de entrada e 3.000 tokens de saída. O custo real deve ser recalculado de acordo com o preço vigente do modelo escolhido no Amazon Bedrock, OpenAI API ou Azure OpenAI.

## 10. Riscos e Controles

| Risco                         | Impacto                                                         | Controle recomendado                                                                                    |
|-------------------------------|-----------------------------------------------------------------|---------------------------------------------------------------------------------------------------------|
| Impacto no ESXi compartilhado | Pode afetar outras VMs se o Ollama consumir CPU/RAM em excesso. | Limitar vCPU/RAM, agendar jobs fora do horário comercial, monitorar host e começar com cargas pequenas. |

|                                    |                                                                        |                                                                                             |
|------------------------------------|------------------------------------------------------------------------|---------------------------------------------------------------------------------------------|
| Dados sensíveis em logs            | Risco de exposição de usuários, IPs, hostnames e eventos de segurança. | Mascaramento, criptografia em repouso, controle de acesso e política clara para modo nuvem. |
| Alucinação da IA                   | Relatórios podem conter interpretação incorreta.                       | Usar dados estruturados, regras determinísticas, revisão humana e evidências anexas.        |
| Base de conhecimento desorganizada | Chatbot pode responder mal ou de forma genérica.                       | Curadoria inicial de documentos, versionamento e validação por especialistas.               |
| Abertura automática de chamados    | Pode gerar ruído operacional.                                          | Manter etapa de revisão humana antes da criação via Octadesk.                               |

## 11. Plano de Implementação por Fases

| Fase                               | Objetivo                                           | Entregas                                                                                             |
|------------------------------------|----------------------------------------------------|------------------------------------------------------------------------------------------------------|
| Fase 1 - Prova de conceito         | Validar fluxo básico em ambiente controlado.       | VM Ubuntu, Ollama, upload de log, parser simples, relatório em tela e geração de texto de chamado.   |
| Fase 2 - MVP integrado             | Integrar fontes reais e Octadesk.                  | Coleta de logs STA, criação assistida de chamado via API, histórico básico e relatórios exportáveis. |
| Fase 3 - Ala técnica com RAG       | Adicionar chatbot com base de conhecimento.        | Upload de documentos, indexação, perguntas técnicas e respostas baseadas em documentação.            |
| Fase 4 - Comparativo local x nuvem | Testar qualidade e custo com Bedrock/OpenAI/Azure. | Alternância de provider, mascaramento, comparação de relatórios e métricas.                          |
| Fase 5 - Produto interno/comercial | Evoluir para uso recorrente e multi-ferramenta.    | RBAC, auditoria, PostgreSQL, Qdrant, integrações adicionais, dashboards e relatórios agendados.      |

## 12. Métricas de Sucesso

- Redução do tempo para criar relatórios executivos a partir de logs.
- Redução do tempo para montar chamados técnicos com evidências e contexto.
- Aumento da padronização de respostas técnicas e relatórios para clientes.
- Capacidade de gerar relatório com dados mascarados e revisão humana.
- Baixo impacto no host ESXi durante testes controlados.
- Aceitação do time técnico e de governança sobre a utilidade das recomendações.

## 13. Recomendação Final

A recomendação é avançar com um MVP em escopo reduzido, aproveitando o ESXi existente e priorizando o fluxo com logs do STA e criação assistida de chamados no Octadesk. O processamento deve ser assíncrono e controlado, com IA local via Ollama em uma primeira validação. Em paralelo, recomenda-se criar uma opção de provider em nuvem, como Amazon Bedrock, para comparação de qualidade, velocidade e custo.

**Frase de apresentação sugerida**

O NeolA Security Portal propõe uma plataforma única de IA para apoiar a operação técnica e a governança em cibersegurança. Na ala técnica, atua como copiloto para troubleshooting e geração assistida de chamados. Na ala de governança, transforma logs de ferramentas como STA e DLP em relatórios executivos e técnicos. A primeira versão pode rodar em uma VM no ESXi existente usando Ollama, com possibilidade de evolução para Bedrock, OpenAI/Azure ou appliance dedicado com GPU.

## 14. Referências Consultadas

- **Amazon Bedrock - Pricing:** <https://aws.amazon.com/bedrock/pricing/>
- **Amazon Bedrock - Visão geral:** <https://docs.aws.amazon.com/bedrock/latest/userguide/what-is-bedrock.html>
- **Ollama API - Documentação:** <https://docs.ollama.com/api/introduction>
- **Ollama API - Autenticação local:** <https://docs.ollama.com/api/authentication>
- **OpenAI API Platform:** <https://openai.com/pt-BR/api/>
- **VMware/Broadcom - VMDirectPath I/O:**  
<https://knowledge.broadcom.com/external/article/309986/configuring-vmdirectpath-io-passthrough.html>

Observação: preços de nuvem e hardware mudam com frequência. Antes de decisão de compra ou contratação, recomenda-se validar valores diretamente nas páginas oficiais e/ou com fornecedores homologados.

## 15. Observações de Segurança e Governança

Como o projeto lida com logs de segurança, recomenda-se adotar desde o MVP práticas de minimização de dados, mascaramento, revisão humana, controle de acesso e trilha de auditoria. A solução deve ser posicionada como suporte à decisão, não como mecanismo automático de resposta a incidentes ou substituição do analista.